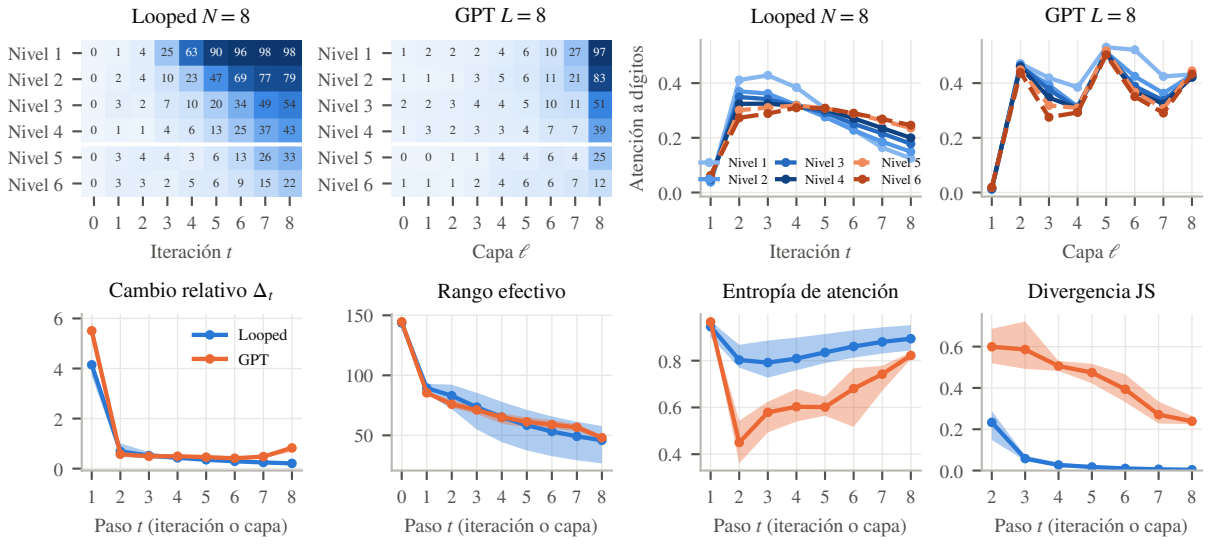
Looped $N = 8$
Nivel 1 0 1 4 25 63 90 96 98 98
Nivel 2 0 2 4 10 23 47 69 77 79
Nivel 3 0 3 2 7 10 20 34 49 54
Nivel 4 0 1 1 4 6 13 25 37 43
Nivel 5 0 3 4 4 3 6 13 26 33
Nivel 6 0 3 3 2 5 6 9 15 22
0 1 2 3 4 5 6 7 8
Iteración t
GPT $L = 8$
Nivel 1 1 2 2 2 4 6 10 27 97
Nivel 2 1 1 1 3 5 6 11 21 83
Nivel 3 2 2 3 4 4 5 10 11 51
Nivel 4 1 3 2 3 3 4 7 7 39
Nivel 5 0 0 1 1 4 4 6 4 25
Nivel 6 1 1 1 2 4 6 6 7 12
0 1 2 3 4 5 6 7 8
Capa ℓ
Looped $N = 8$
Atención a dígitos
0.0 0.2 0.4
Nivel 1 Nivel 2 Nivel 3 Nivel 4 Nivel 5 Nivel 6
1 2 3 4 5 6 7 8
Iteración t
GPT $L = 8$
0.0 0.2 0.4
1 2 3 4 5 6 7 8
Capa ℓ
Cambio relativo Δ_t
0 2 4 6
Looped
GPT
1 2 3 4 5 6 7 8
Paso t (iteración o capa)
Rango efectivo
50 100 150
0 1 2 3 4 5 6 7 8
Paso t (iteración o capa)
Entropía de atención
0.4 0.6 0.8
1 2 3 4 5 6 7 8
Paso t (iteración o capa)
Divergencia JS
0.0 0.2 0.4 0.6
2 3 4 5 6 7 8
Paso t (iteración o capa)